NIR-Spektroskopie zur Hesperidin-Quantifizierung in Mandarinenschalen

1. Projektübersicht

Ziel dieses Projekts ist die Quantifizierung des Hesperidin-Gehalts in Zitrusschalen mittels NIR-Spektroskopie. Zwei NIR-Spektrometer wurden verglichen:

- **TANGO (Bruker FT-NIR):** Laborspektrometer, 4000–10000 cm^{-1}, 1501 Wellenzahlen
- **NeoSpectra (Handheld NIR):** Tragbares Spektrometer, 1351–2558 nm, 141 Wellenlängen

Als Referenz dienen HPLC-bestimmte Hesperidin-Gehalte (%) für 12 Proben.

2. Daten

2.1 Probenmaterial

Probe	Beschreibung	Hesperidin (%)
2	G, EDEKA (Grapefruit)	3.33
3	Z, Rewe Spanien (Zitrone)	2.47
5	L, Rewe Vietnam (Limette)	2.12
15	M, Bio Markt lose Pa	4.27
16	M, Bio Markt lose Pb	3.30
18	M, EDEKA Spanien Pb	2.96
19	M, Rewe Spanien Pa	3.69
21	M, Penny Spanien Pa	2.84
24	M, EDEKA Spanien Nadorcott Pb	3.63
25	M, Rewe Bio Spanien Pb	4.50
26	M, Rewe Bio Spanien Pa	4.22
28	M, EDEKA Bio Spanien Pb	3.82

2.2 Spektren

- **TANGO:** 219 Spektren total (21 Proben × ~10 Wiederholungen), davon 120 mit HPLC-Referenz (12 Proben)
- **NeoSpectra:** 200 Spektren total (20 Proben × 10 Wiederholungen), davon 120 mit HPLC-Referenz (12 Proben)
- Nach Mittelung der Wiederholungsmessungen: je 12 gemittelte Spektren pro Datensatz

3. Vorverarbeitung

Folgende Vorverarbeitungsschritte wurden durchgeführt: 1. **Mittelung** der Wiederholungsmessungen pro Probe 2. **SNV (Standard Normal Variate)** – Korrektur von Streueffekten 3. **Savitzky-Golay Glättung** (Fenster=15, Polynom=2) 4. **SG 1. Ableitung** – zur Verstärkung spektraler Merkmale

TANGO – Vorverarbeitung (nach Probe)

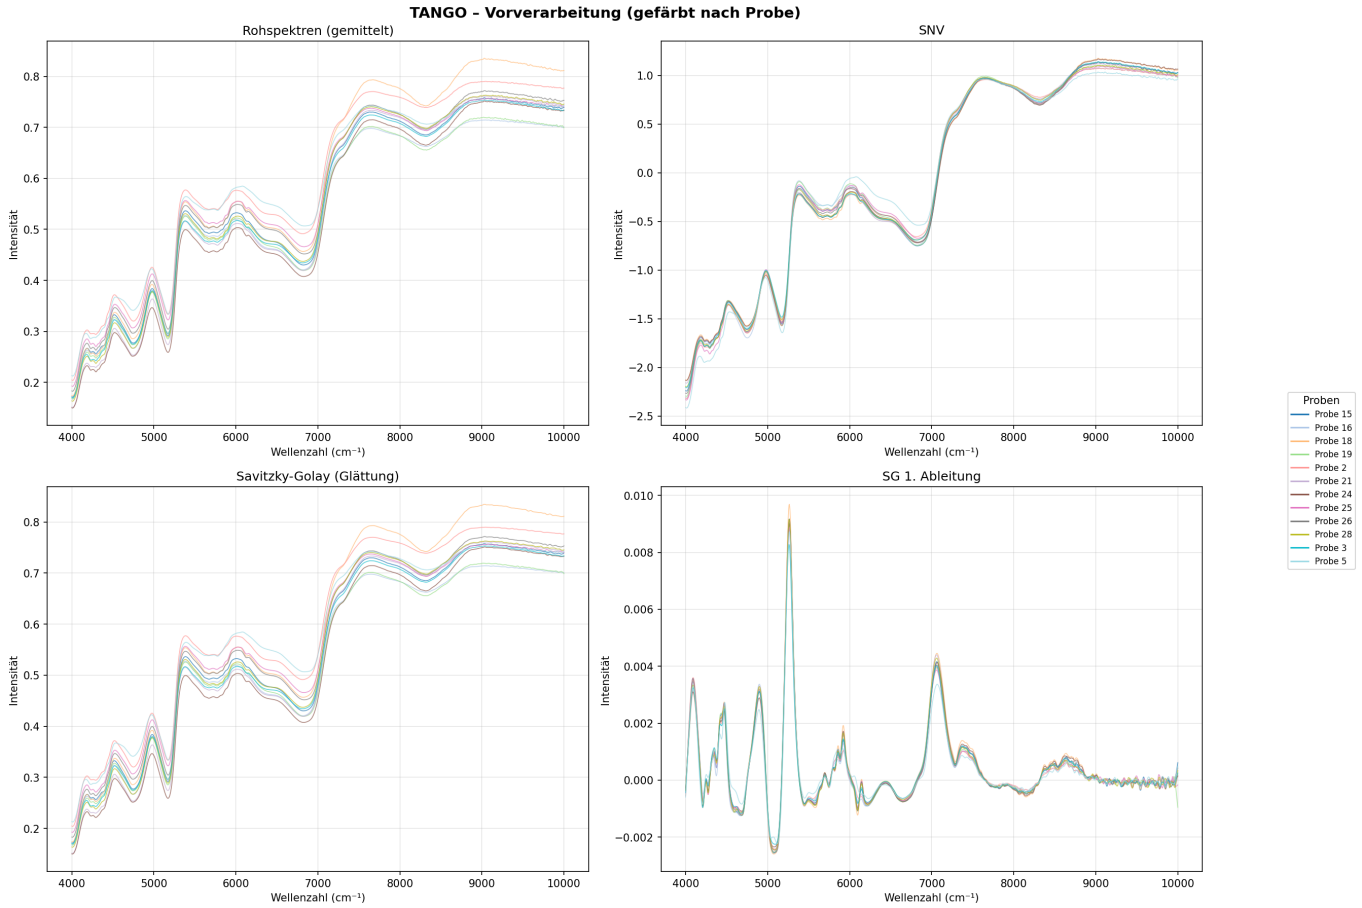

TANGO – Vorverarbeitung (nach Gehalt)

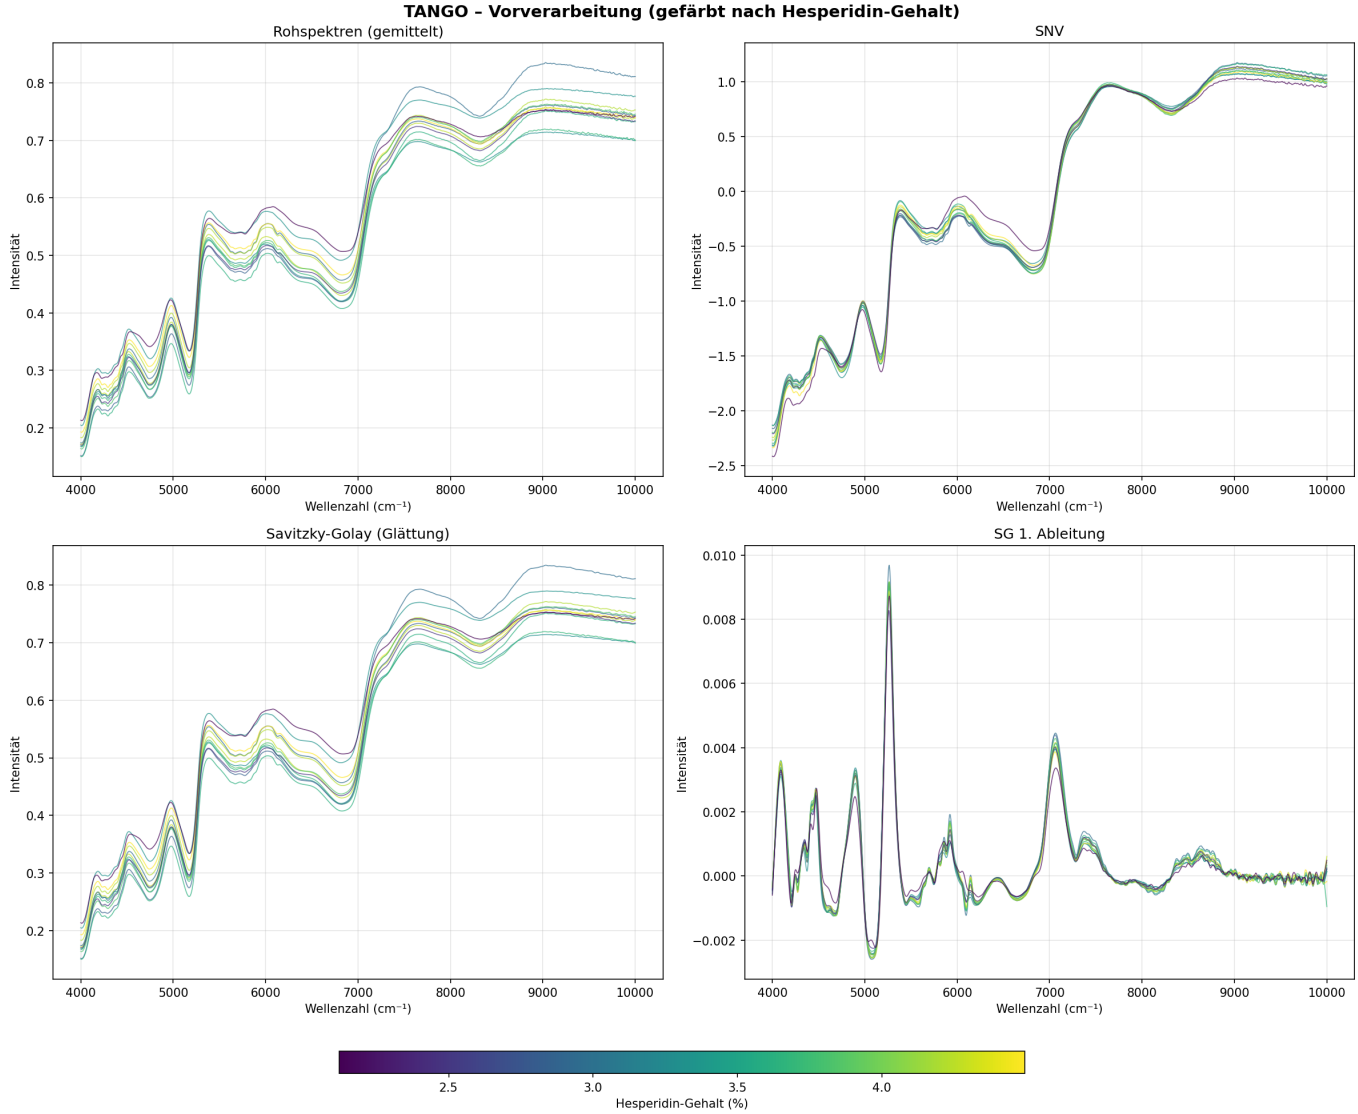

NeoSpectra – Vorverarbeitung (nach Probe)

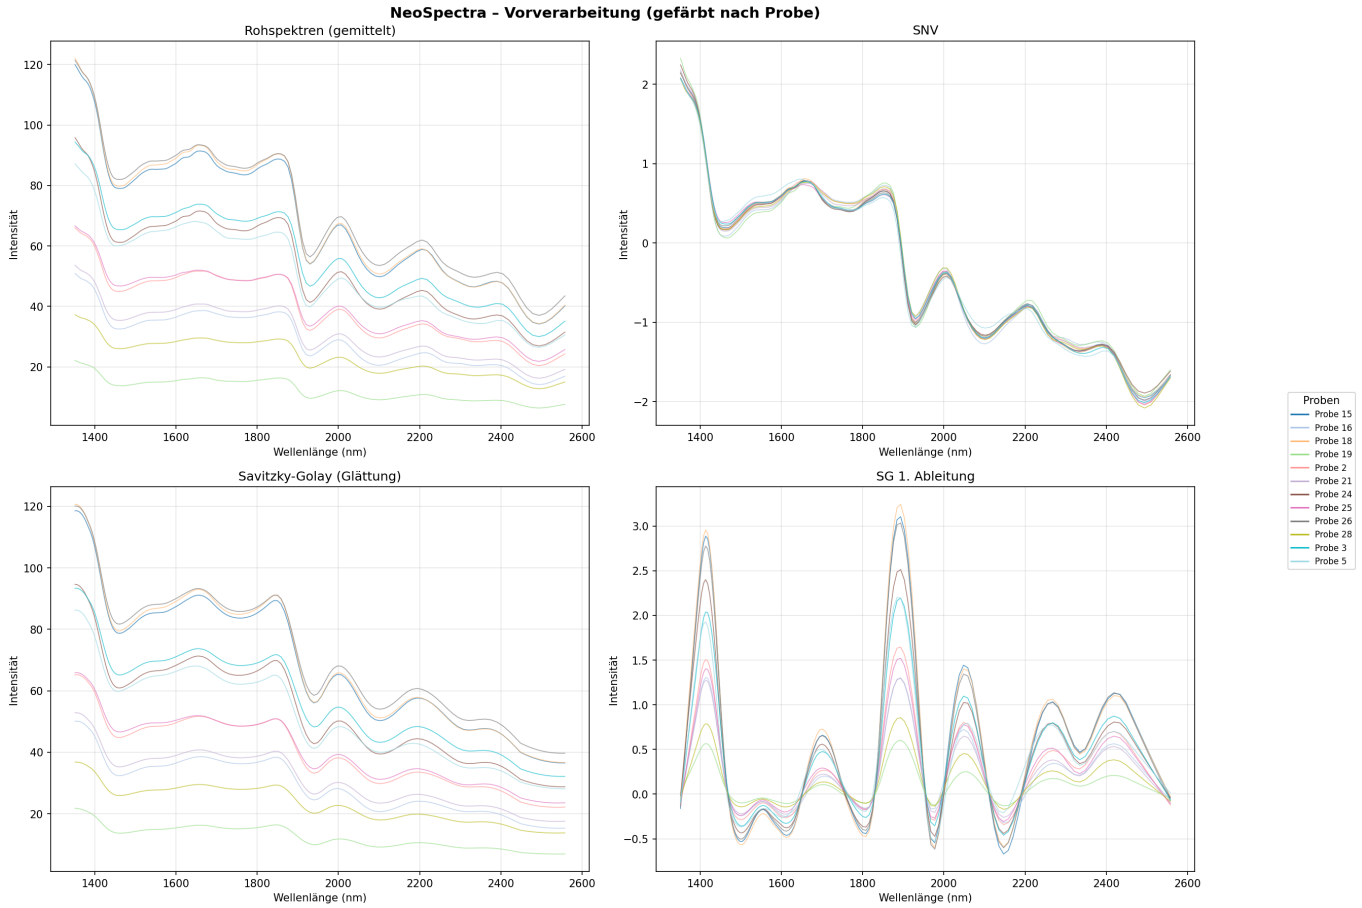

NeoSpectra – Vorverarbeitung (nach Gehalt)

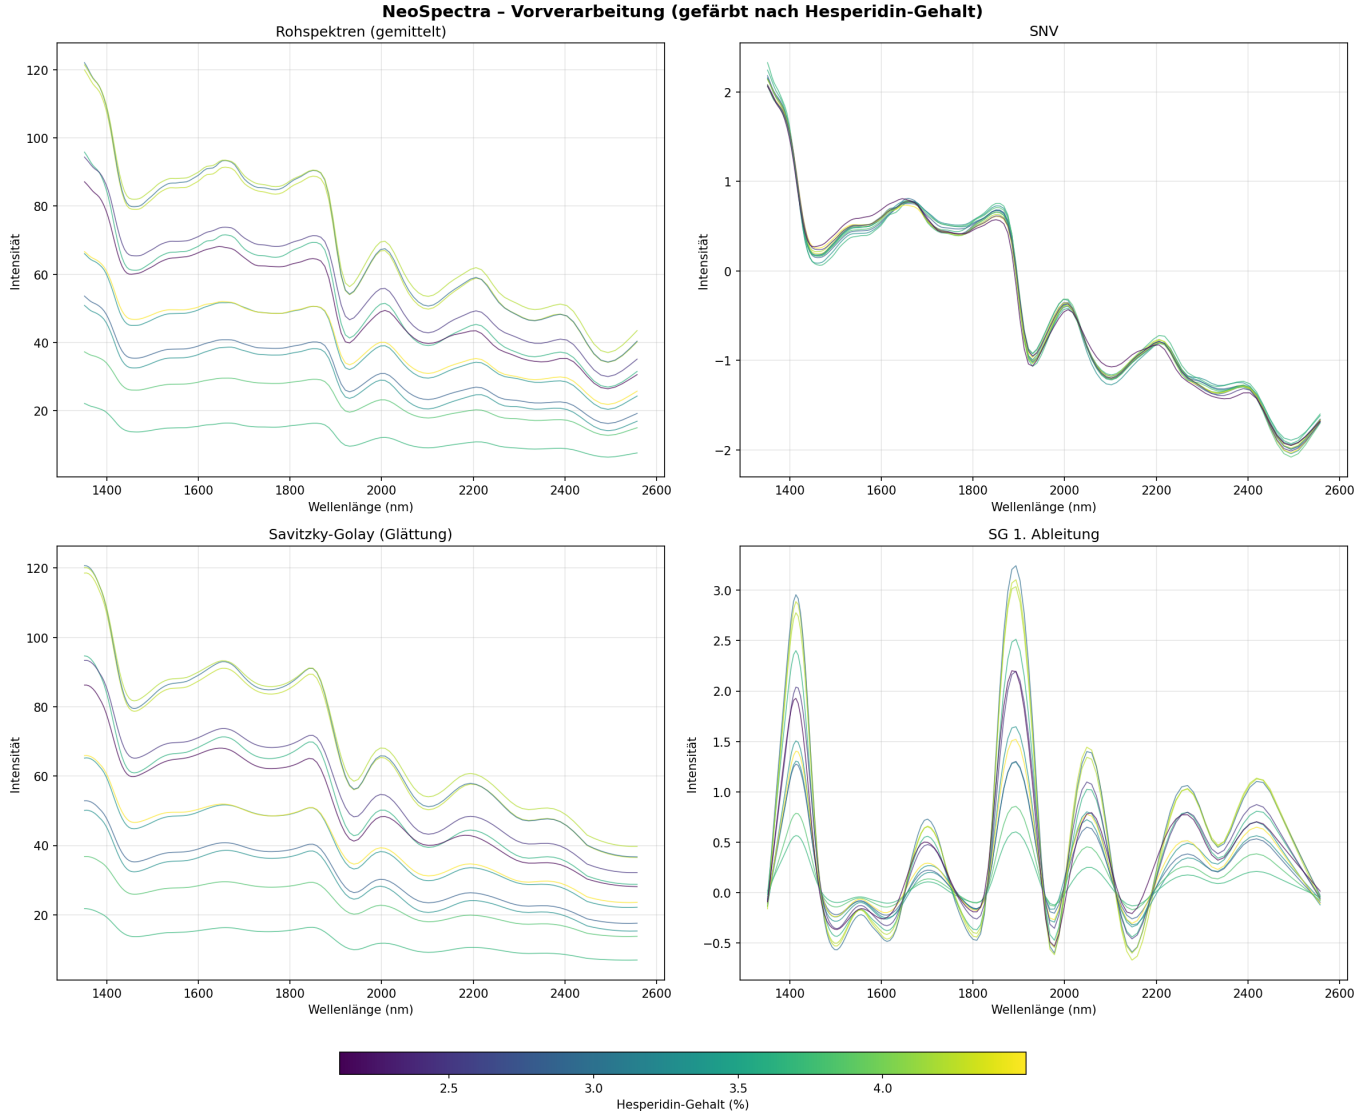

4. PLS-Regression

PLS-Regression (Partial Least Squares) wurde mit Leave-One-Out Kreuzvalidierung (LOO-CV) auf den SNV-vorverarbeiteten, gemittelten Spektren durchgeführt. Die Komponentenzahl wurde von 1–11 optimiert.

4.1 TANGO

- **Optimale Komponentenzahl:** 1
- **RMSECV:** 1.1895%
- **R^2CV:** -1.8555

Das negative R^2CV zeigt, dass das Modell schlechter als der Mittelwert vorhersagt. Bei nur 12 Proben und LOO-CV ist die Validierung instabil.

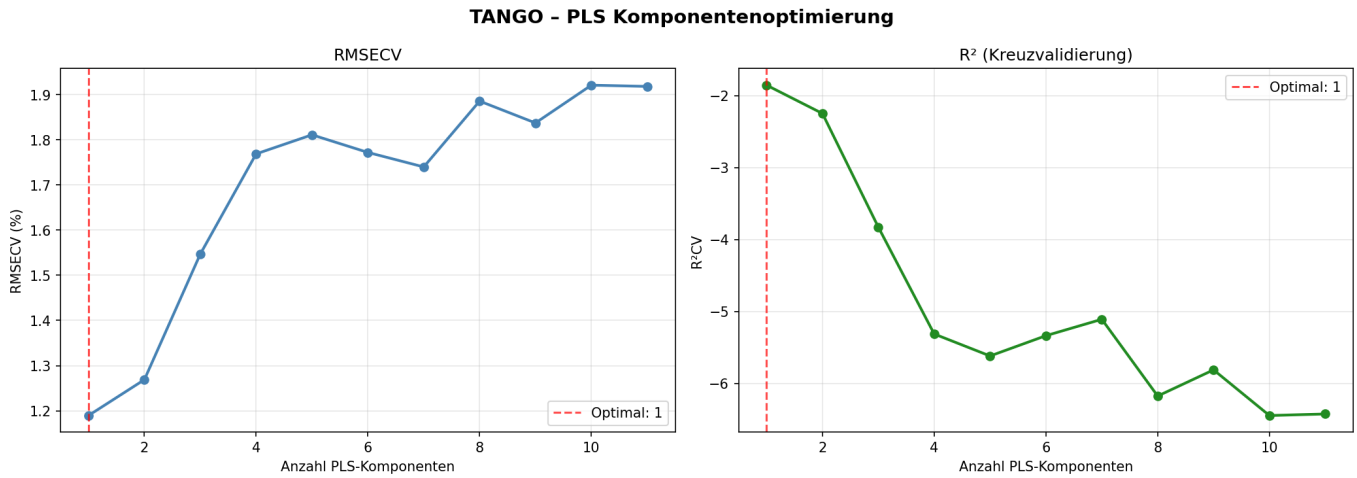
TANGO – PLS Komponentenoptimierung
RMSECV
RMSECV (%)
Anzahl PLS-Komponenten
Optimal: 1
R² (Kreuzvalidierung)
R²CV
Anzahl PLS-Komponenten
Optimal: 1

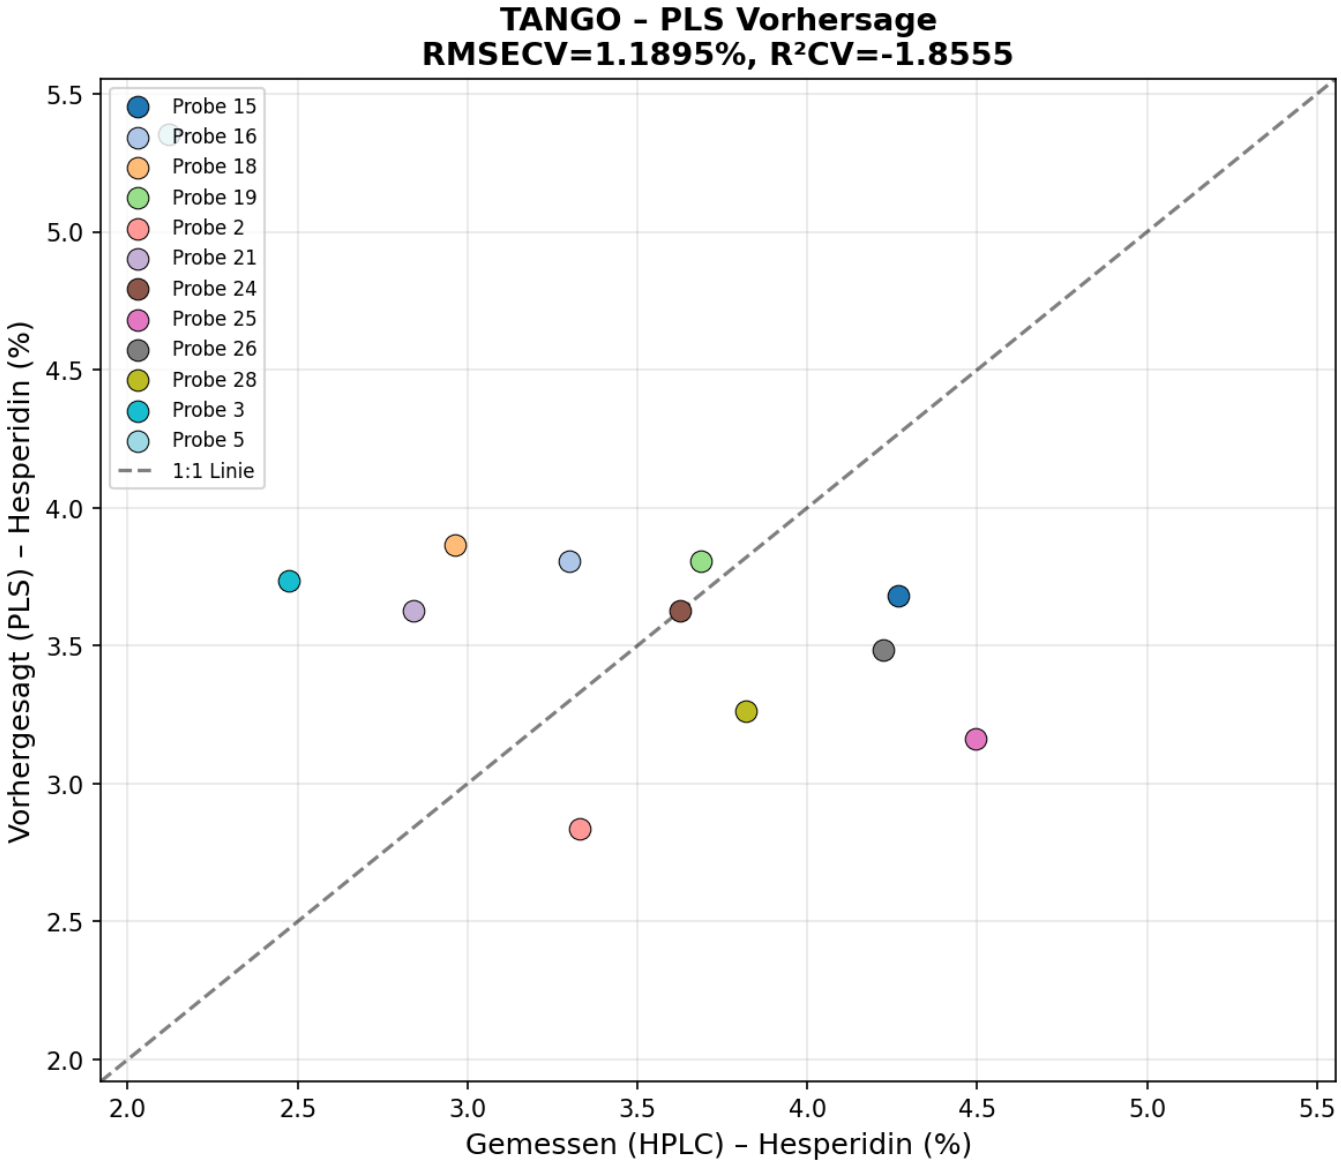
TANGO – PLS Vorhersage
RMSECV=1.1895%, R²CV=-1.8555
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
1:1 Linie
Vorhergesagt (PLS) – Hesperidin (%)
Gemessen (HPLC) – Hesperidin (%)

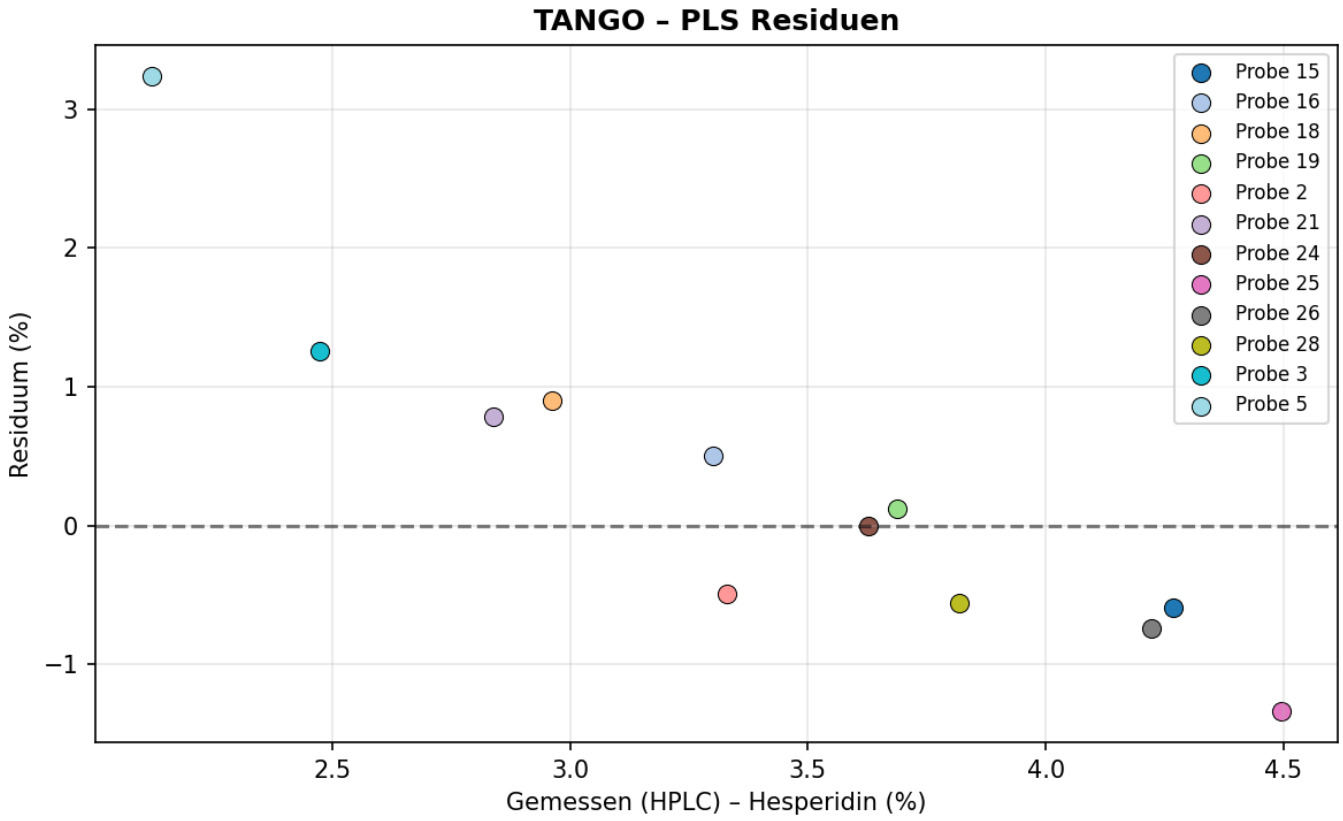

4.2 NeoSpectra

- **Optimale Komponentenzahl:** 7
- **RMSECV:** 0.7472%
- **R²CV:** -0.1268

Das NeoSpectra-Modell performt besser als das TANGO-Modell, ist aber ebenfalls nicht prädiktiv ($R^2CV < 0$).

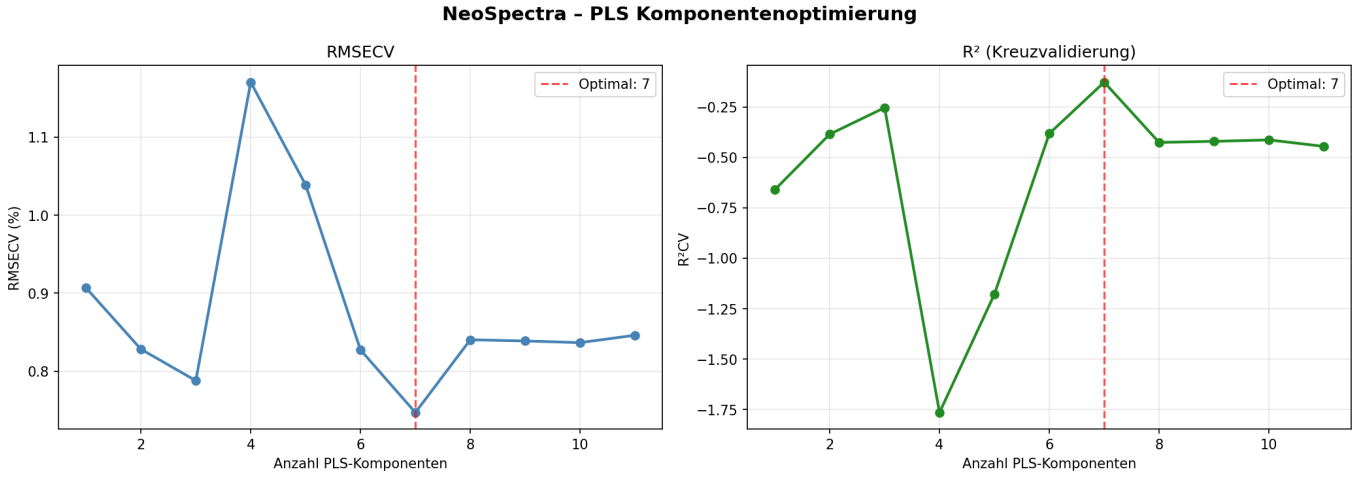

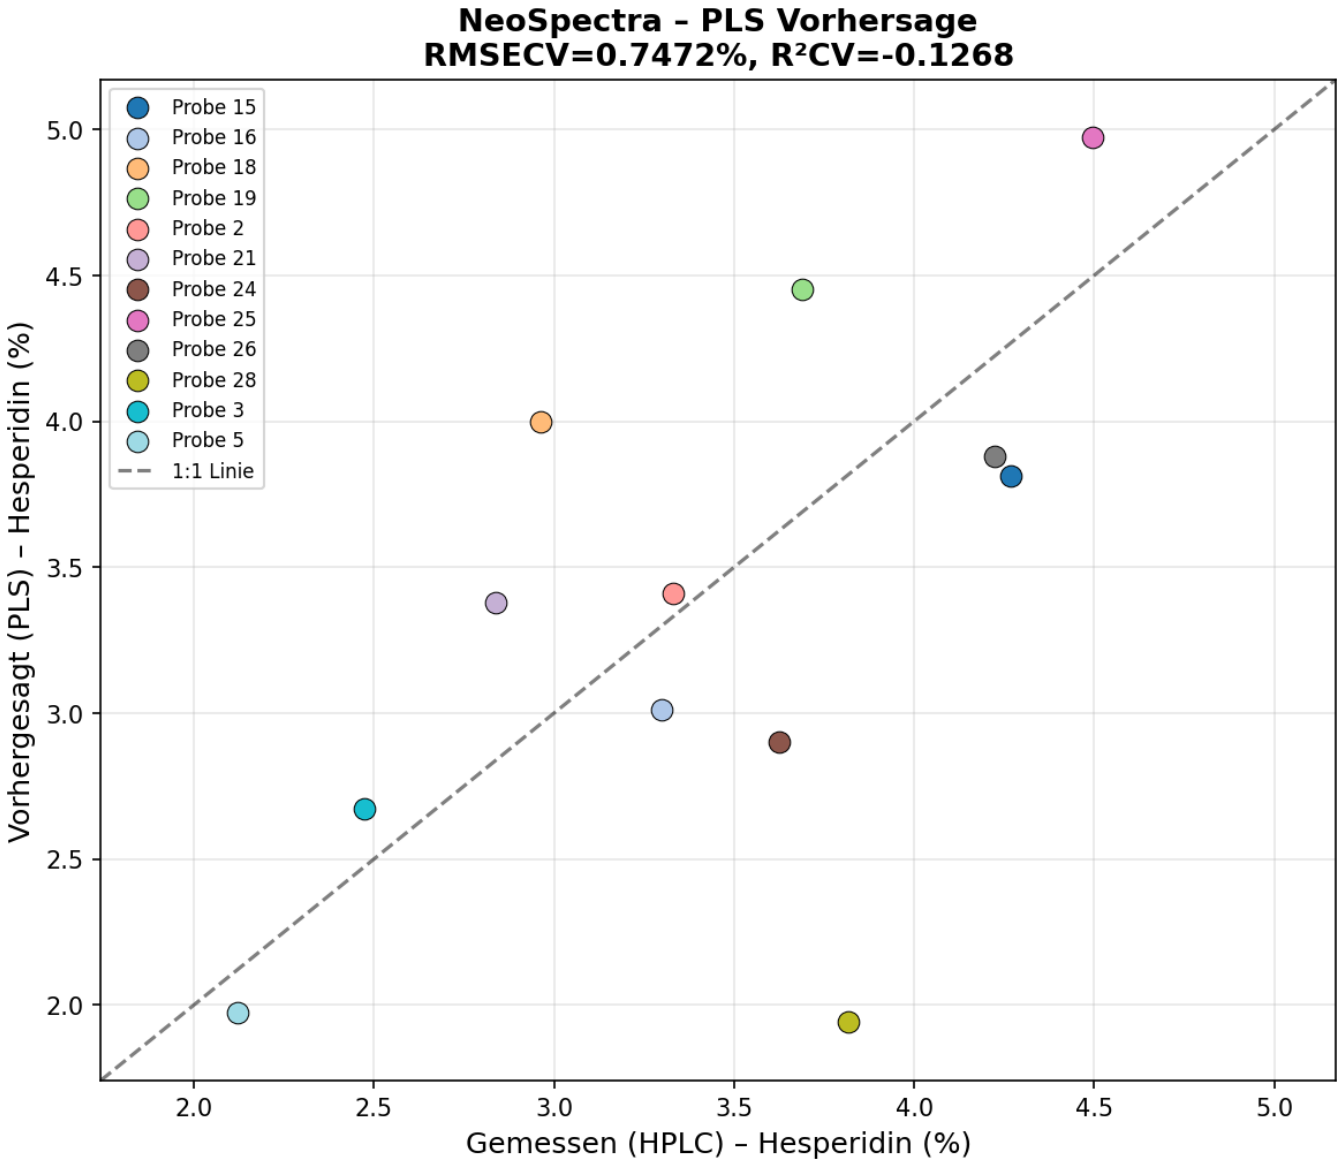
NeoSpectra – PLS Vorhersage
RMSECV=0.7472%, R²CV=-0.1268
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
1:1 Linie
Vorhergesagt (PLS) – Hesperidin (%)
Gemessen (HPLC) – Hesperidin (%)
2.0
2.5
3.0
3.5
4.0
4.5
5.0

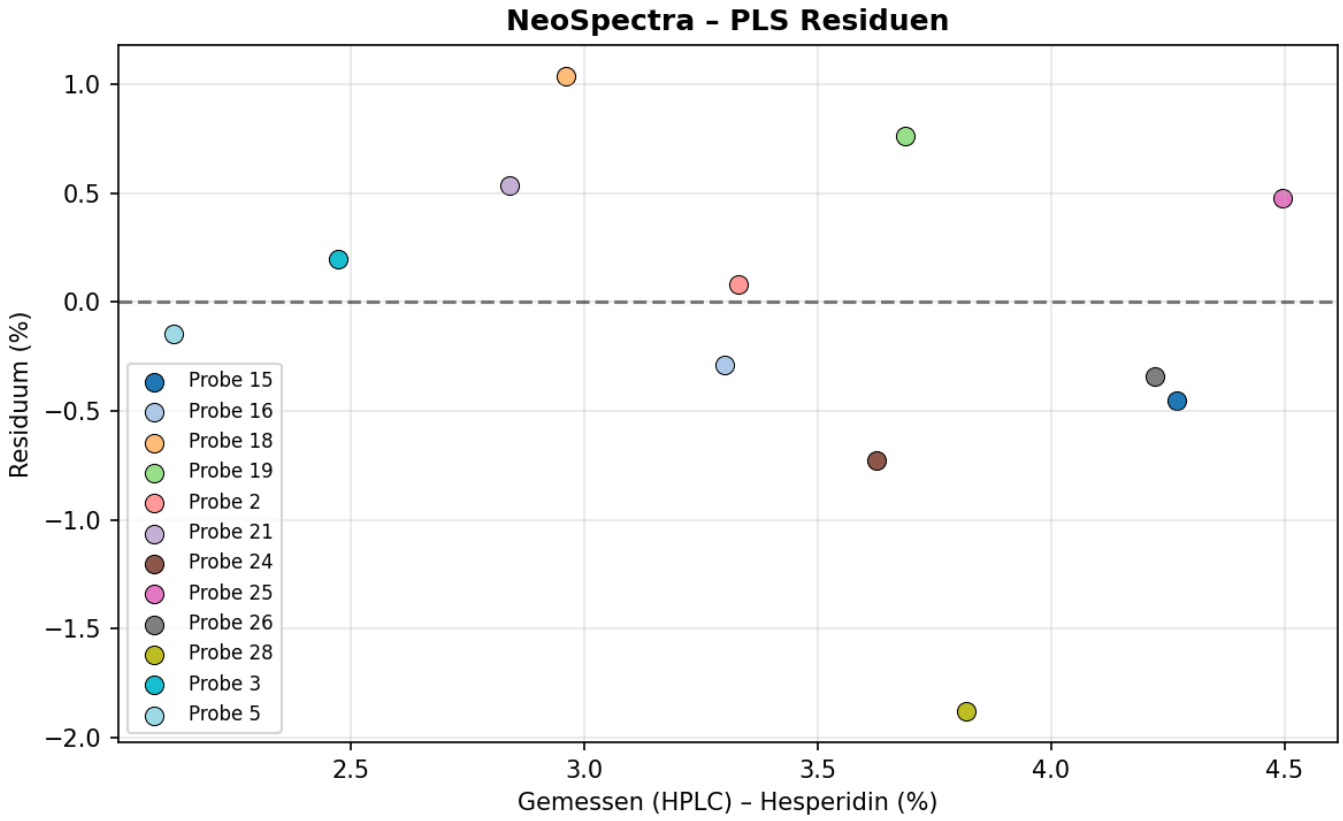

4.3 Bewertung

Die schlechte PLS-Performance ist auf die **sehr geringe Probenanzahl (n=12)** zurückzuführen. Für robuste PLS-Modelle werden typischerweise >30 Kalibierproben benötigt. Zudem ist die Varianz der Hesperidin-Gehalte gering (2.1–4.5%). Empfehlungen: - Mehr Kalibierproben sammeln - Breiteren Konzentrationsbereich abdecken - Verschiedene Vorverarbeitungen systematisch testen

5. Dimensionsreduktion

PCA, UMAP und t-SNE wurden auf den SNV-vorverarbeiteten, gemittelten Spektren durchgeführt.

5.1 TANGO

PCA

- Erklärte Varianz: PC1=57.3%, PC2=21.7% (Total: 79.0%)

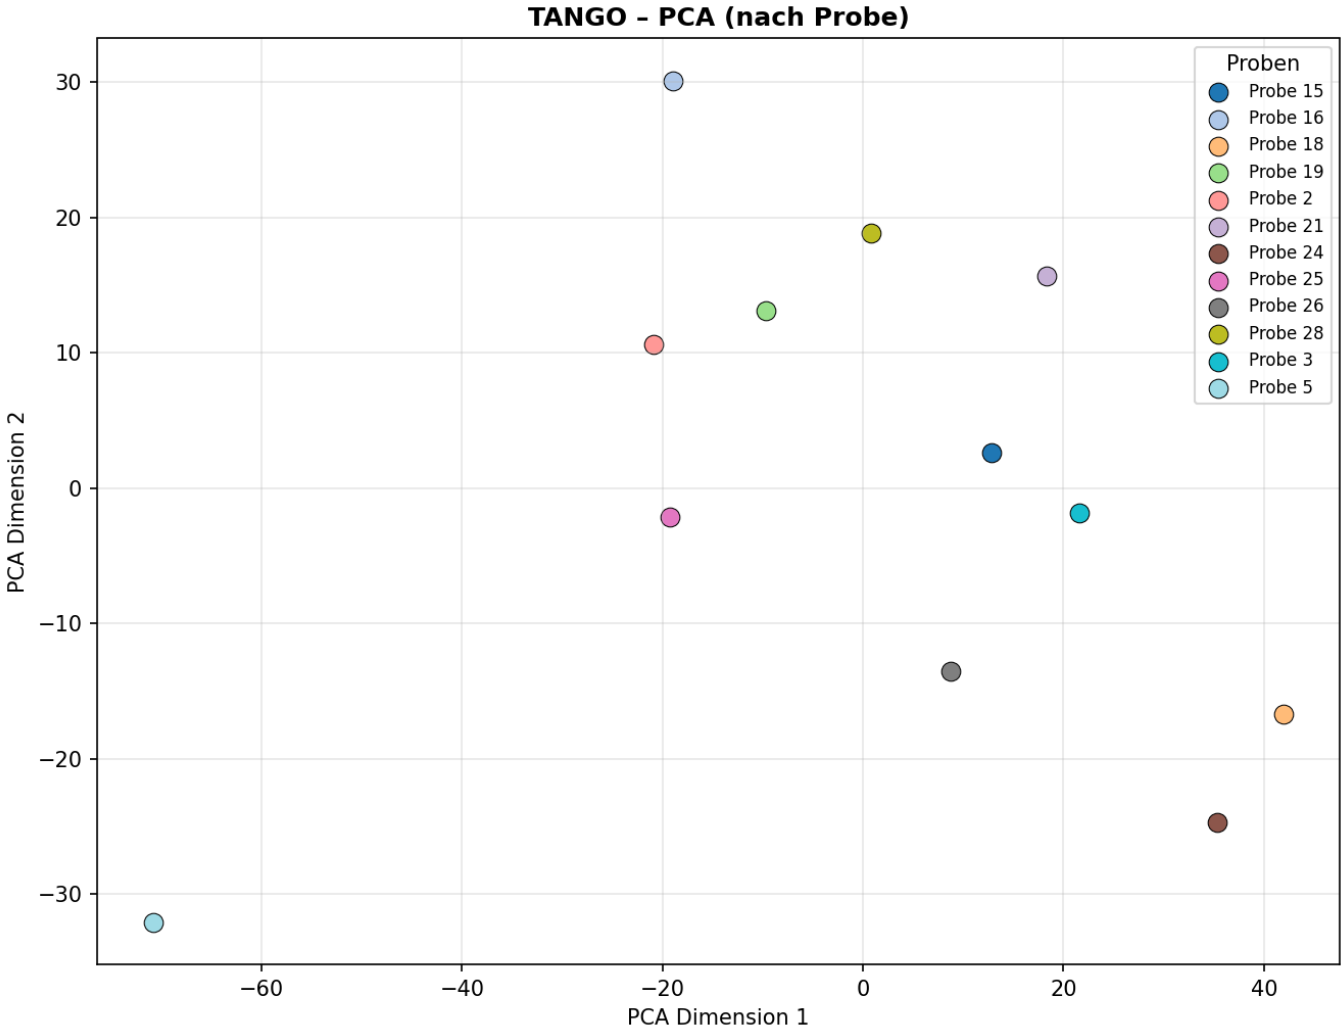
TANGO – PCA (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
PCA Dimension 2
PCA Dimension 1
30
20
10
0
−10
−20
−30
−60
−40
−20
0
20
40

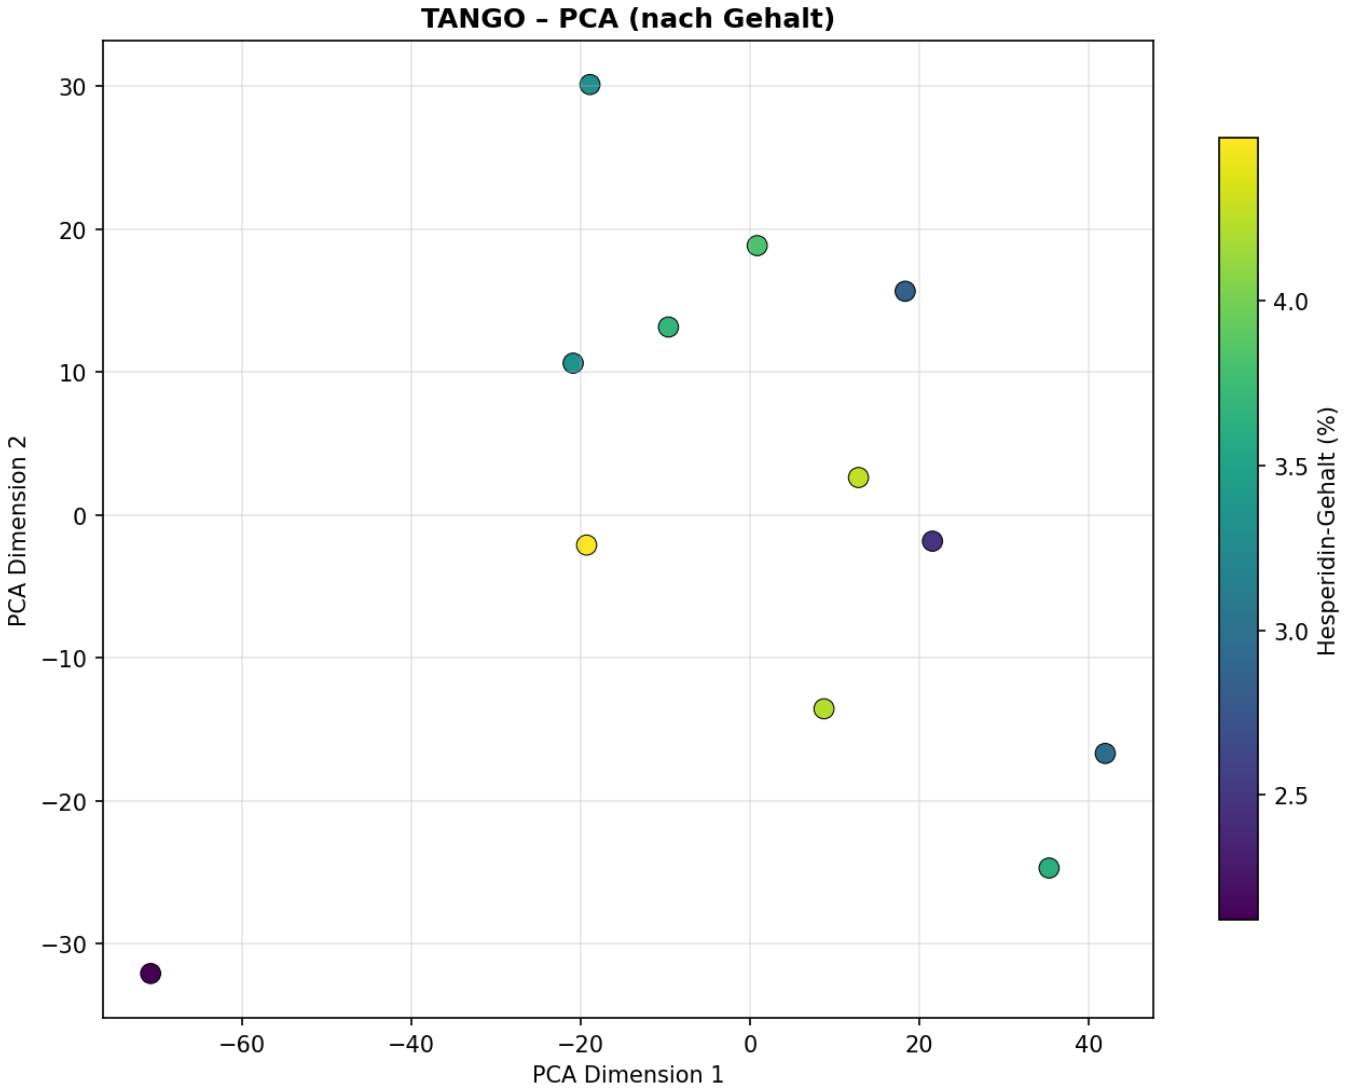
TANGO – PCA (nach Gehalt)
PCA Dimension 2
PCA Dimension 1
Hesperidin-Gehalt (%)
30
20
10
0
−10
−20
−30
−60
−40
−20
0
20
40
4.0
3.5
3.0
2.5

UMAP

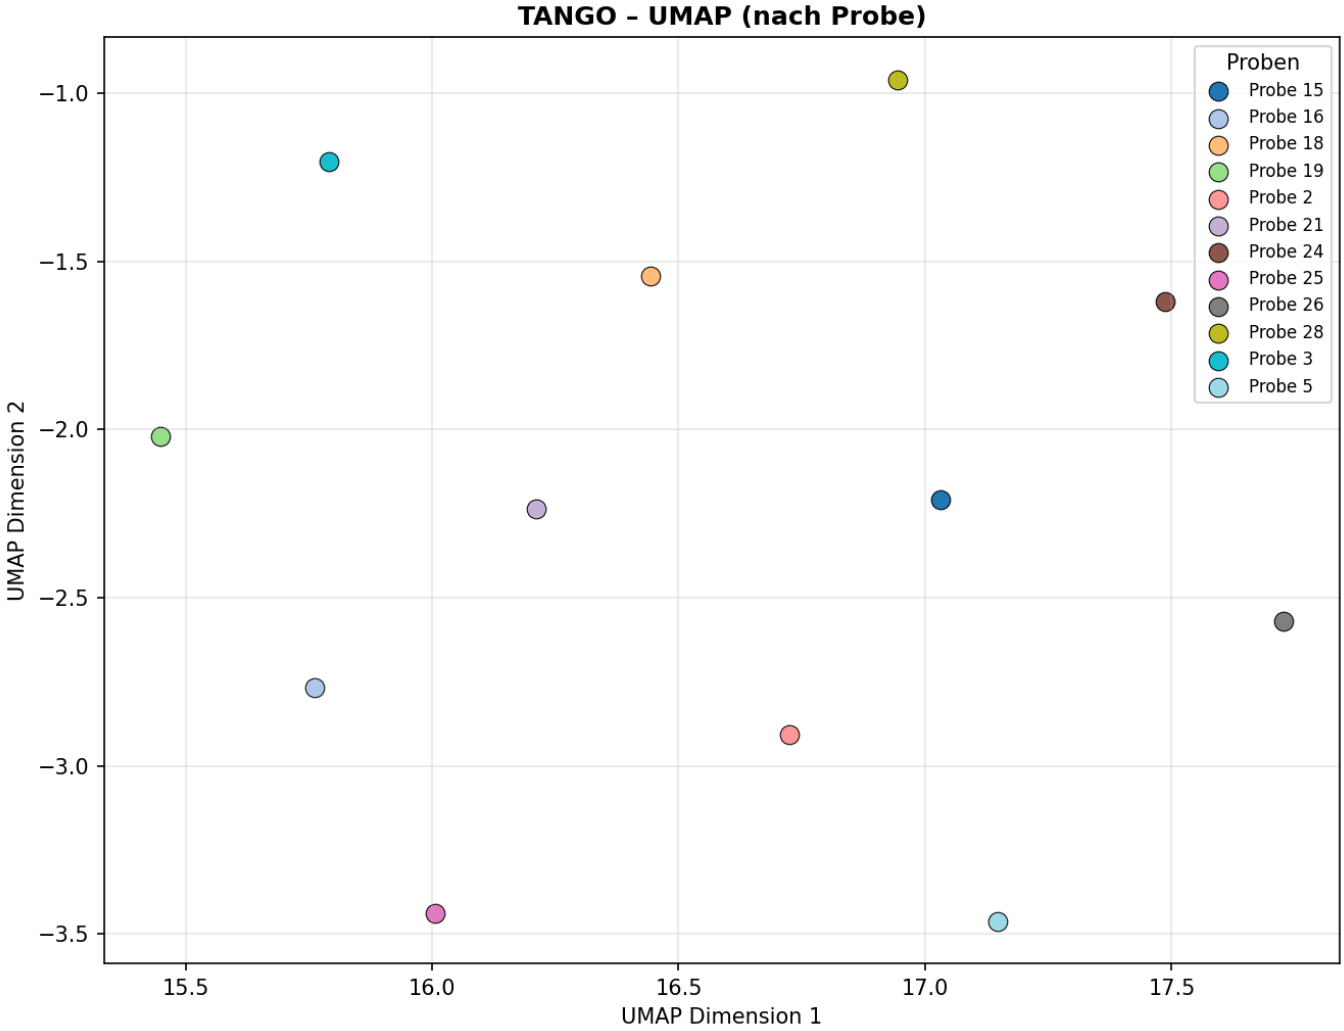
TANGO – UMAP (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
−1.0
−1.5
−2.0
−2.5
−3.0
−3.5
UMAP Dimension 2
15.5
16.0
16.5
17.0
17.5
UMAP Dimension 1

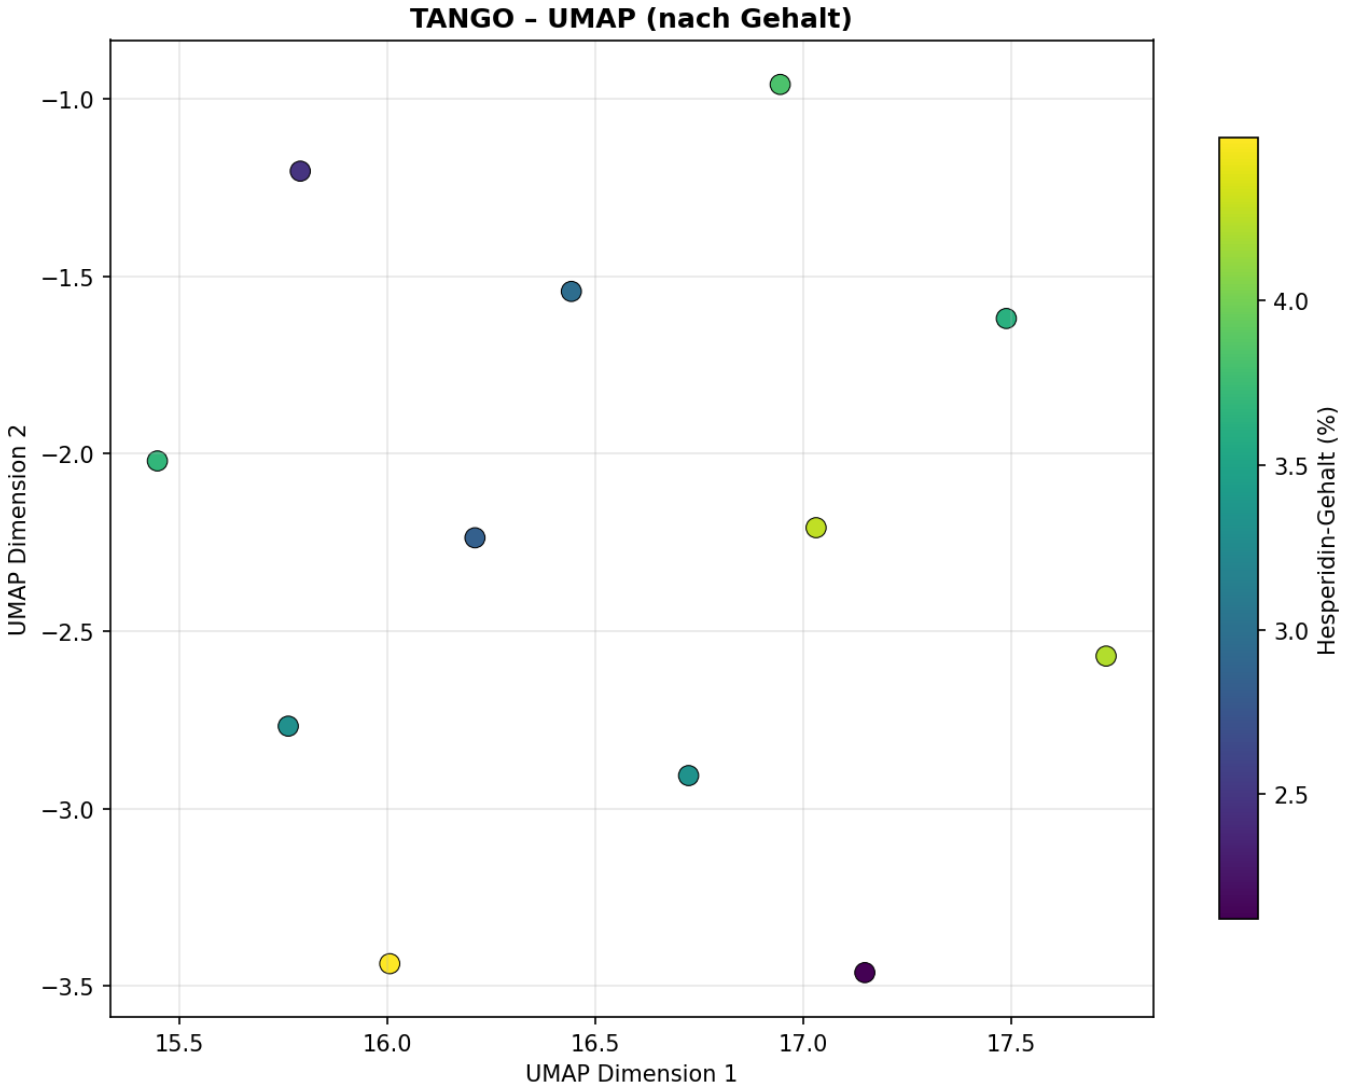

t-SNE

- KL-Divergenz: 0.2869

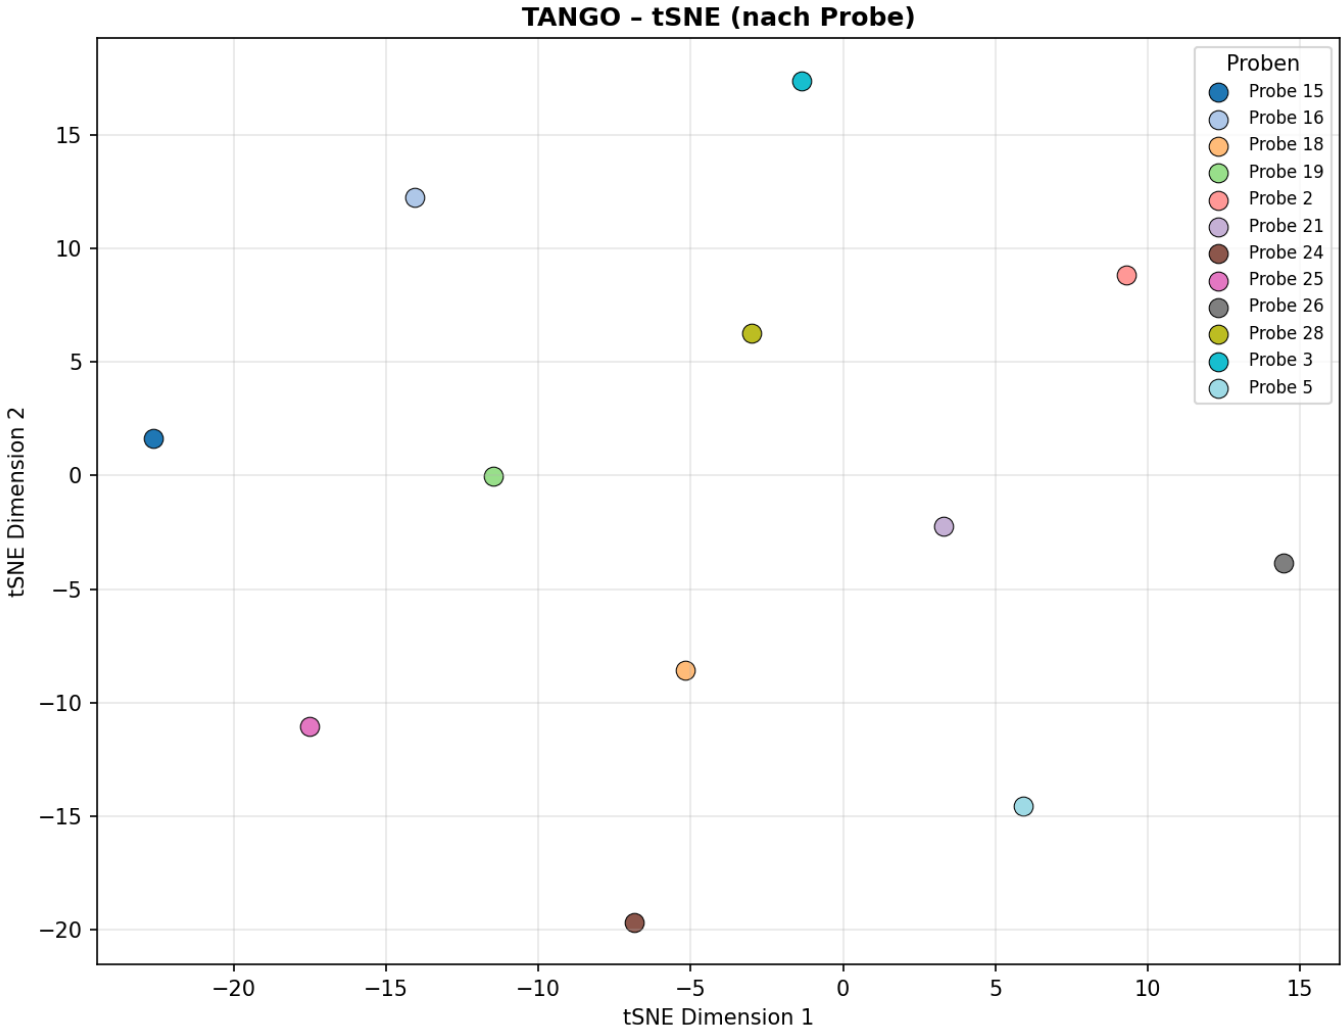
TANGO – tSNE (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
tSNE Dimension 1
tSNE Dimension 2
−20
−15
−10
−5
0
5
10
15

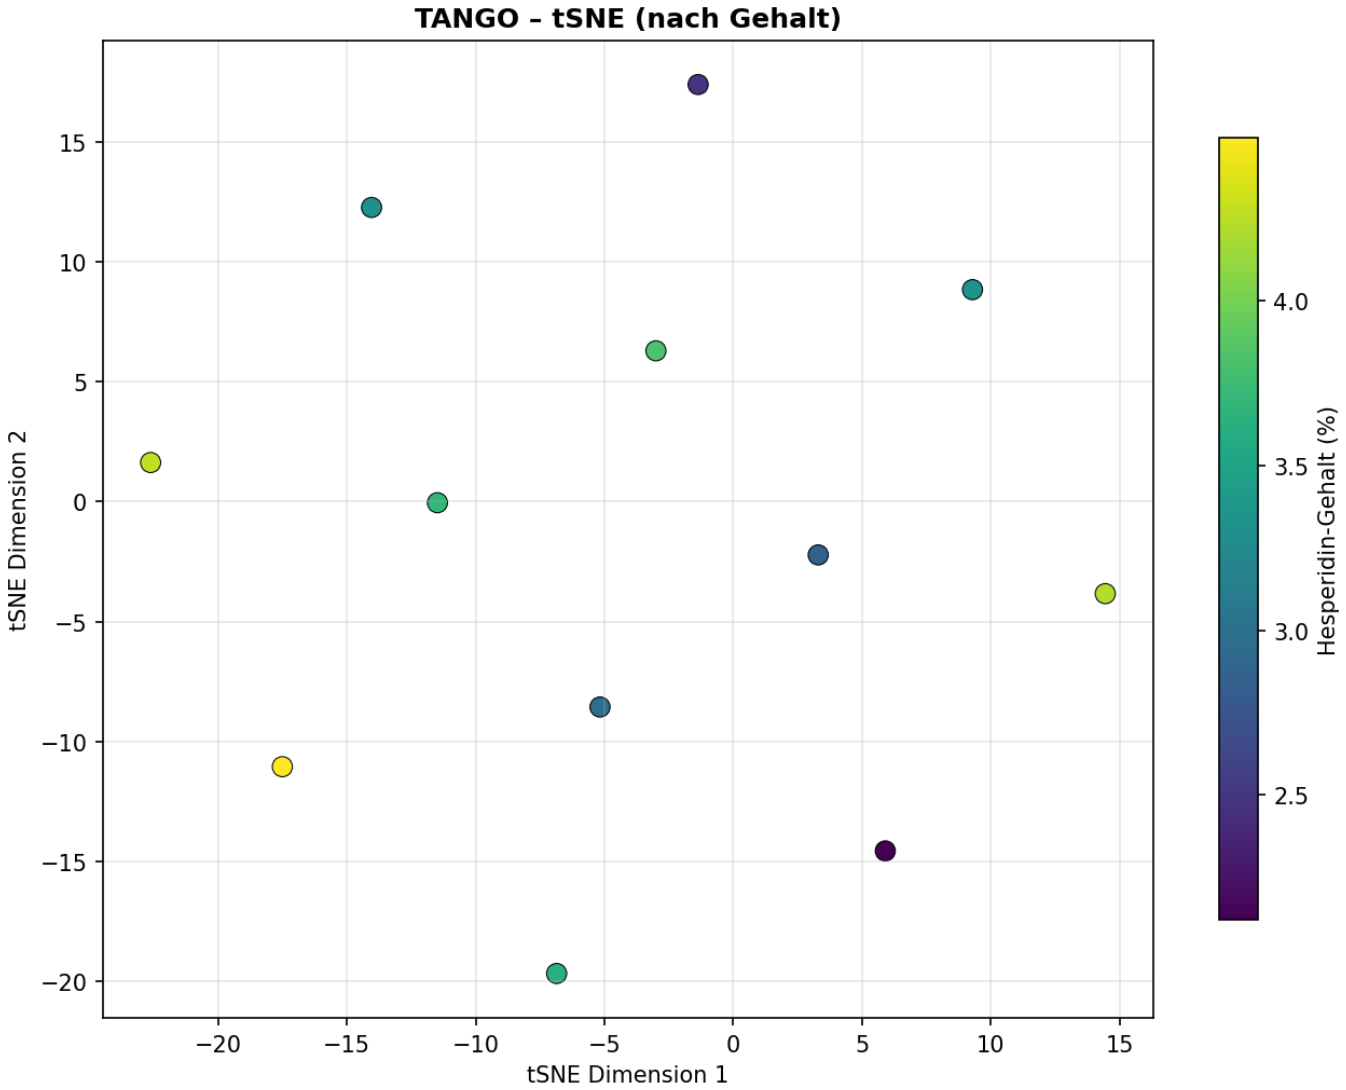

5.2 NeoSpectra

PCA

- Erklärte Varianz: PC1=54.4%, PC2=25.8% (Total: 80.2%)

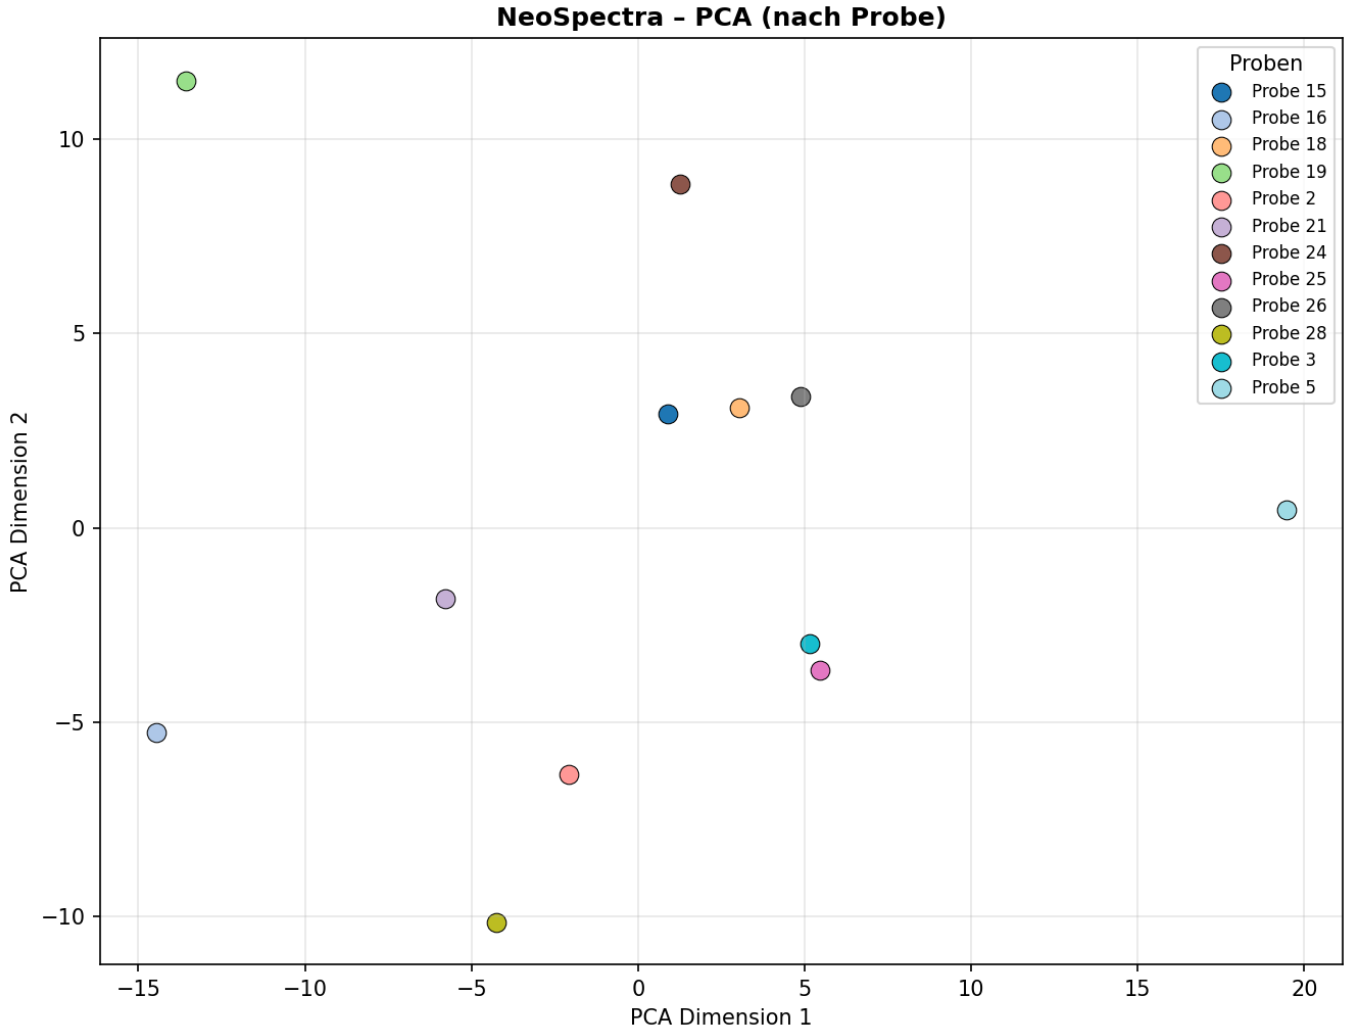
NeoSpectra – PCA (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
PCA Dimension 2
PCA Dimension 1
10
5
0
−5
−10
−15
−10
−5
0
5
10
15
20

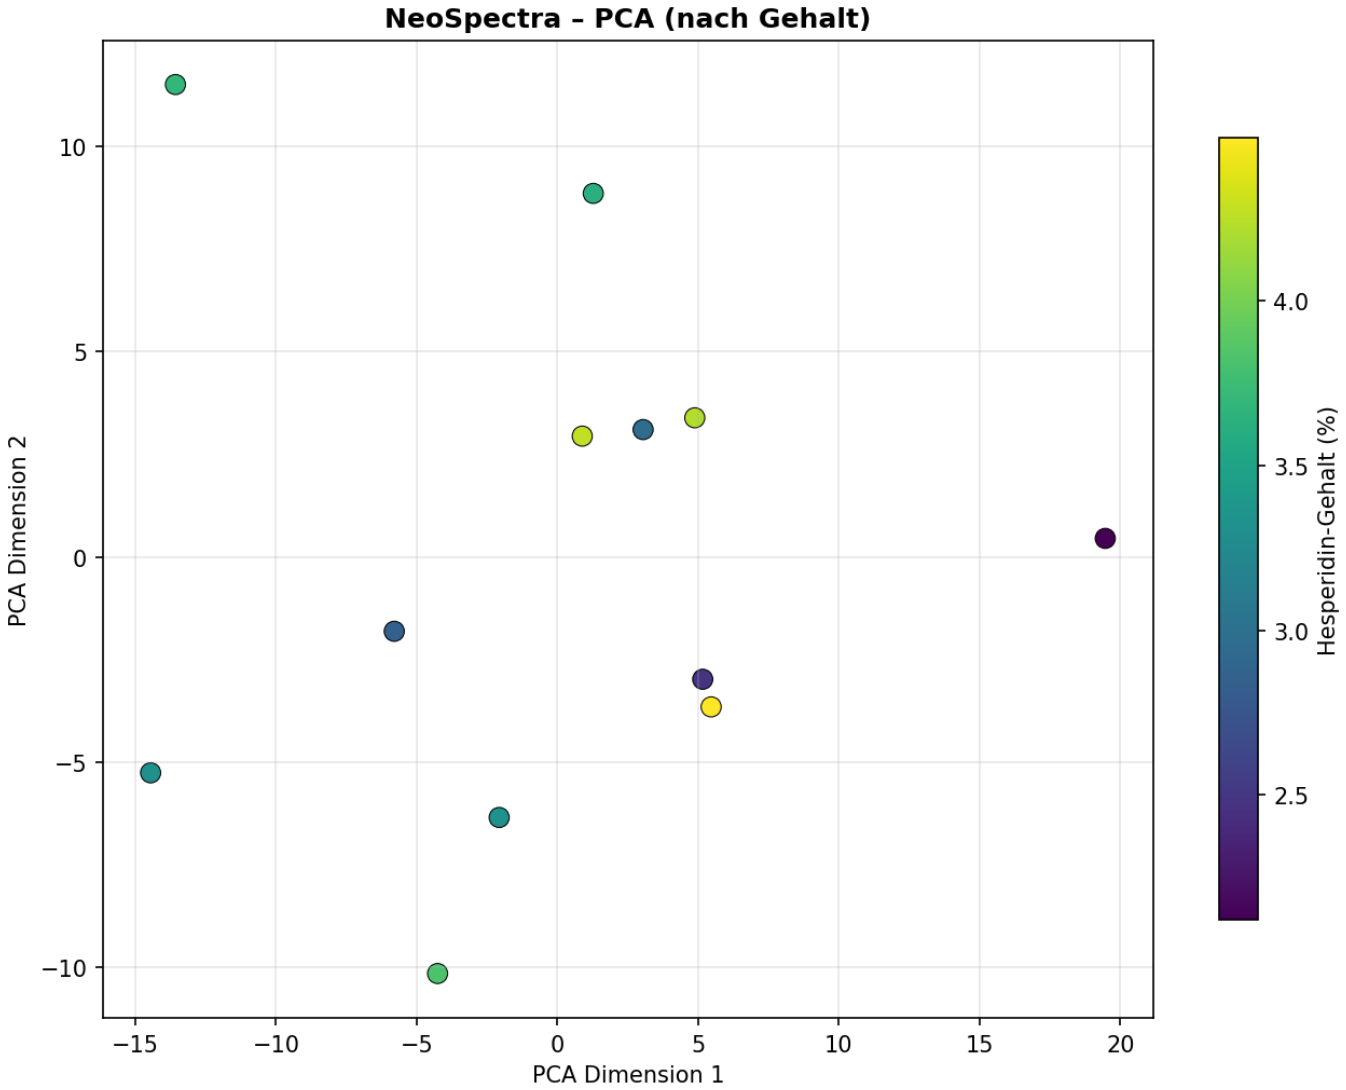
NeoSpectra – PCA (nach Gehalt)
PCA Dimension 2
PCA Dimension 1
Hesperidin-Gehalt (%)
10
5
0
−5
−10
−15
−10
−5
0
5
10
15
20
4.0
3.5
3.0
2.5

UMAP

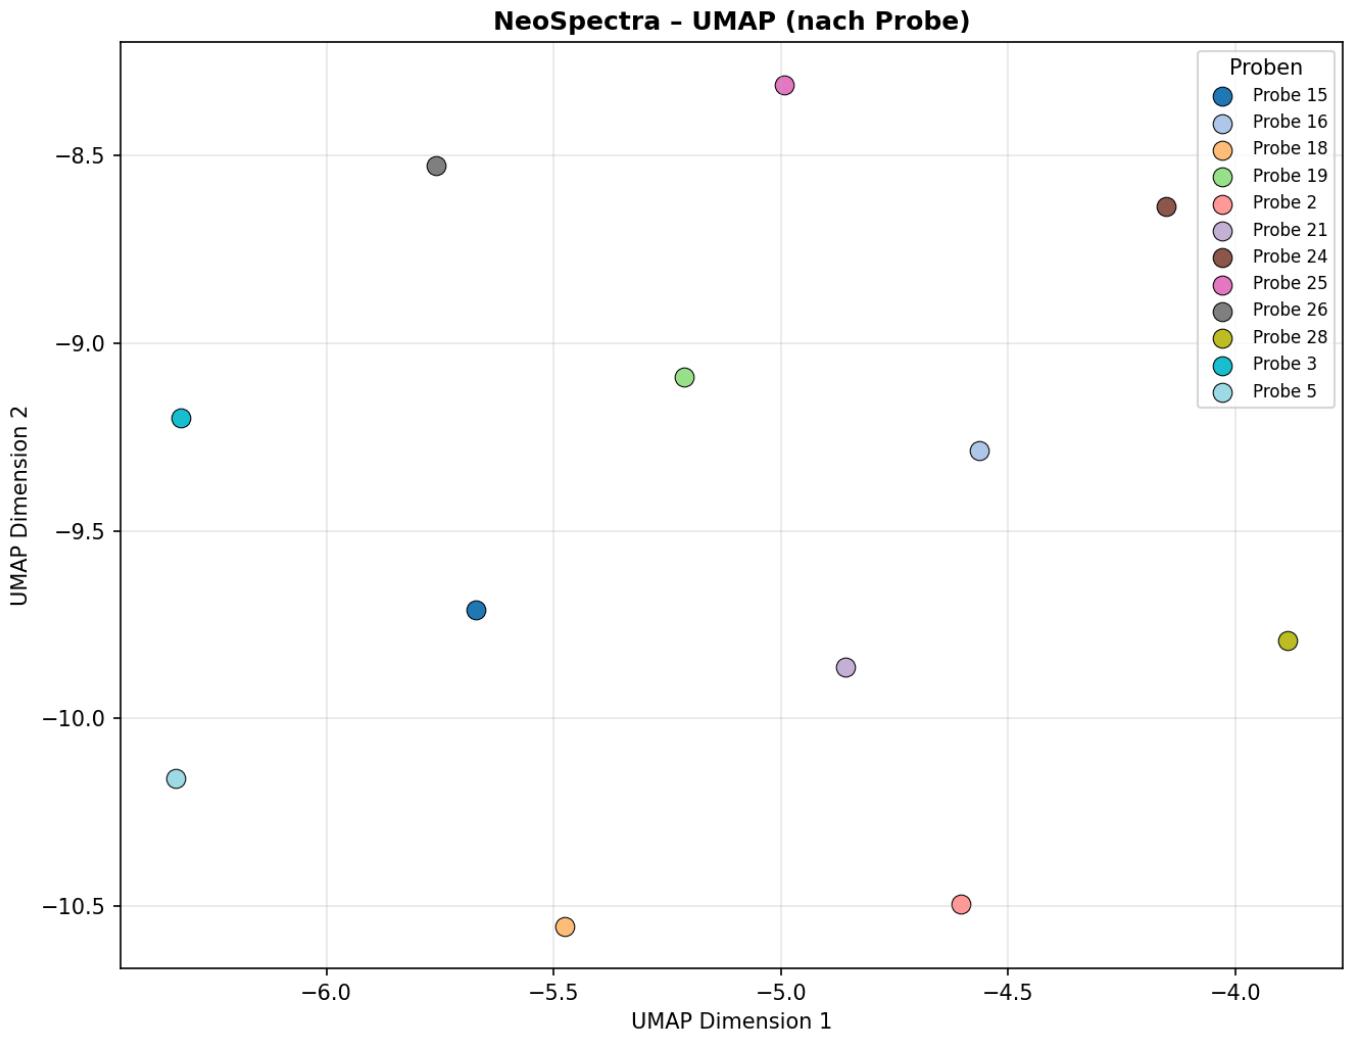
NeoSpectra – UMAP (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
−8.5
−9.0
−9.5
−10.0
−10.5
UMAP Dimension 2
−6.0
−5.5
−5.0
−4.5
−4.0
UMAP Dimension 1

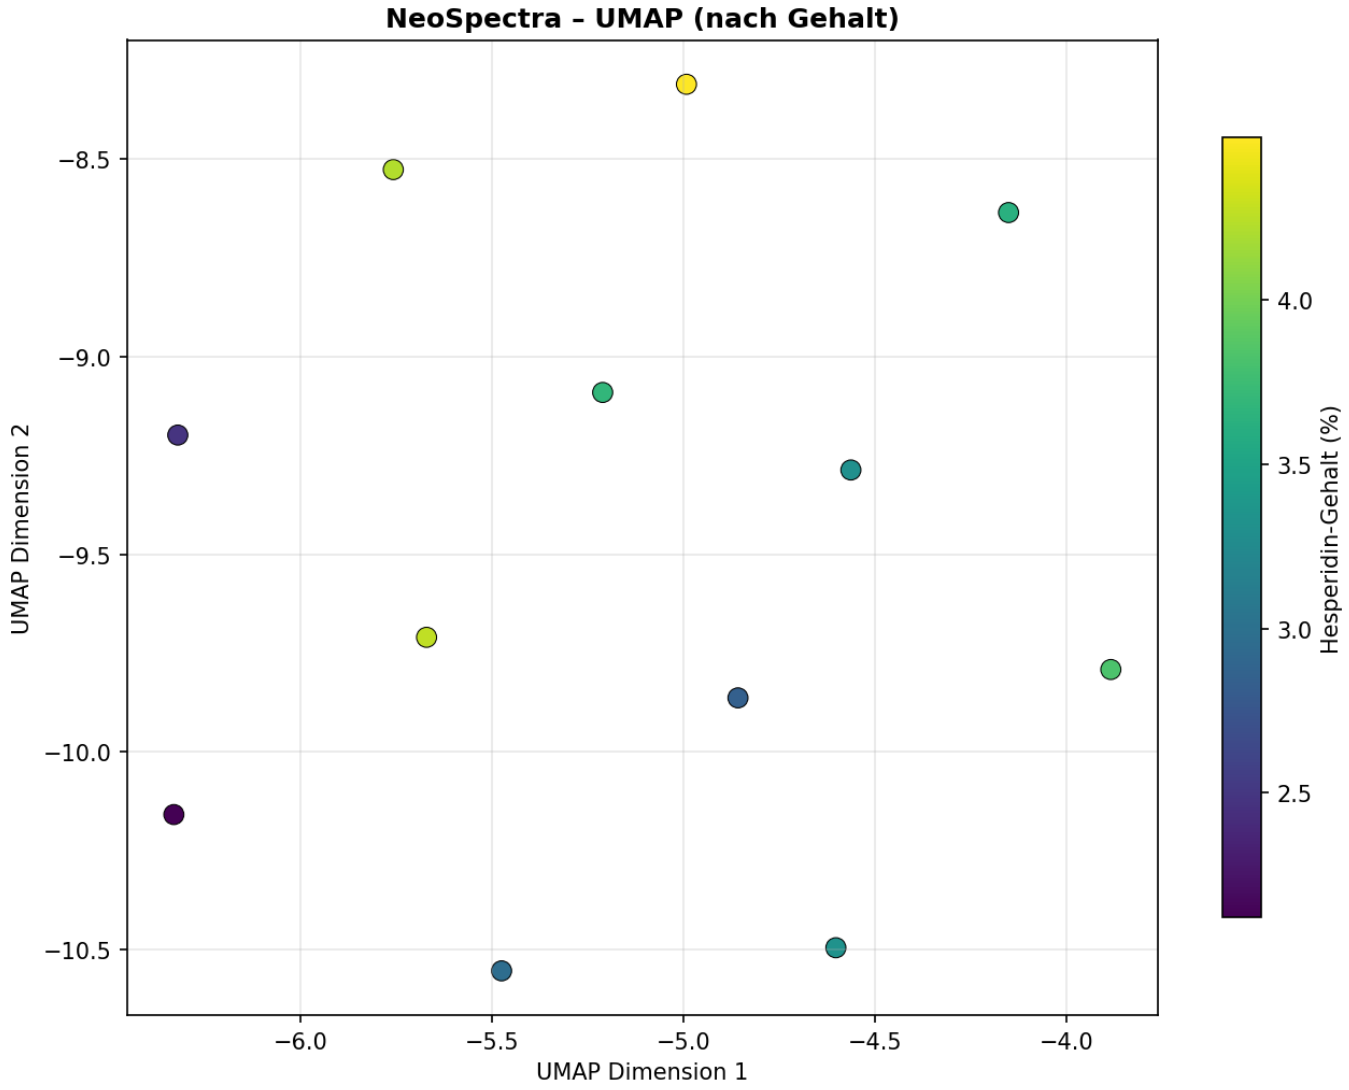

t-SNE

- KL-Divergenz: 0.2904

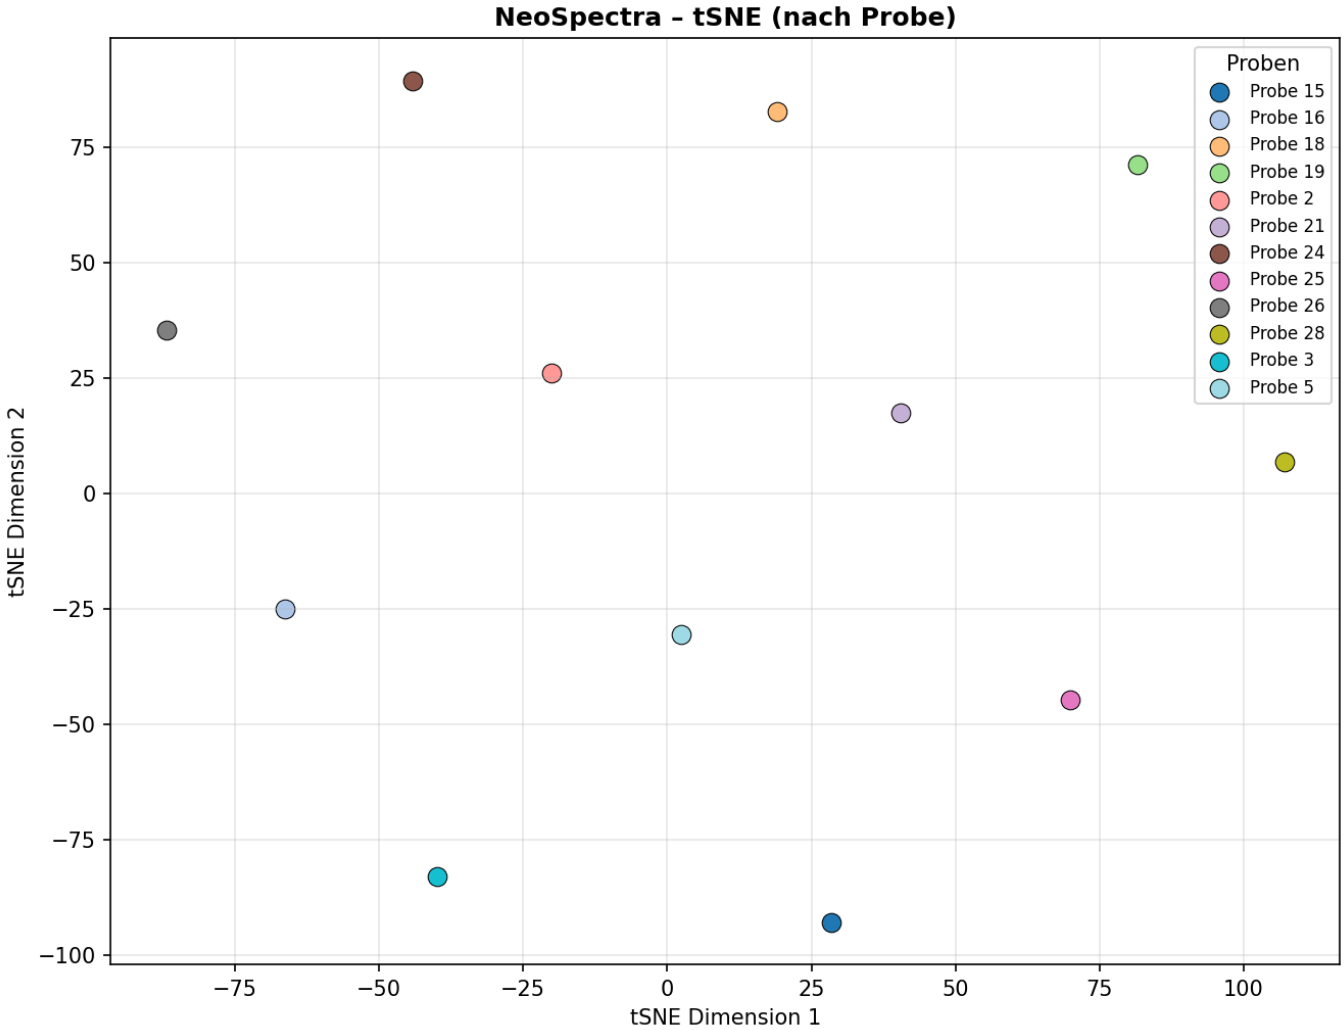
NeoSpectra – tSNE (nach Probe)
Proben
Probe 15
Probe 16
Probe 18
Probe 19
Probe 2
Probe 21
Probe 24
Probe 25
Probe 26
Probe 28
Probe 3
Probe 5
tSNE Dimension 1
tSNE Dimension 2
−75
−50
−25
0
25
50
75
100
−100

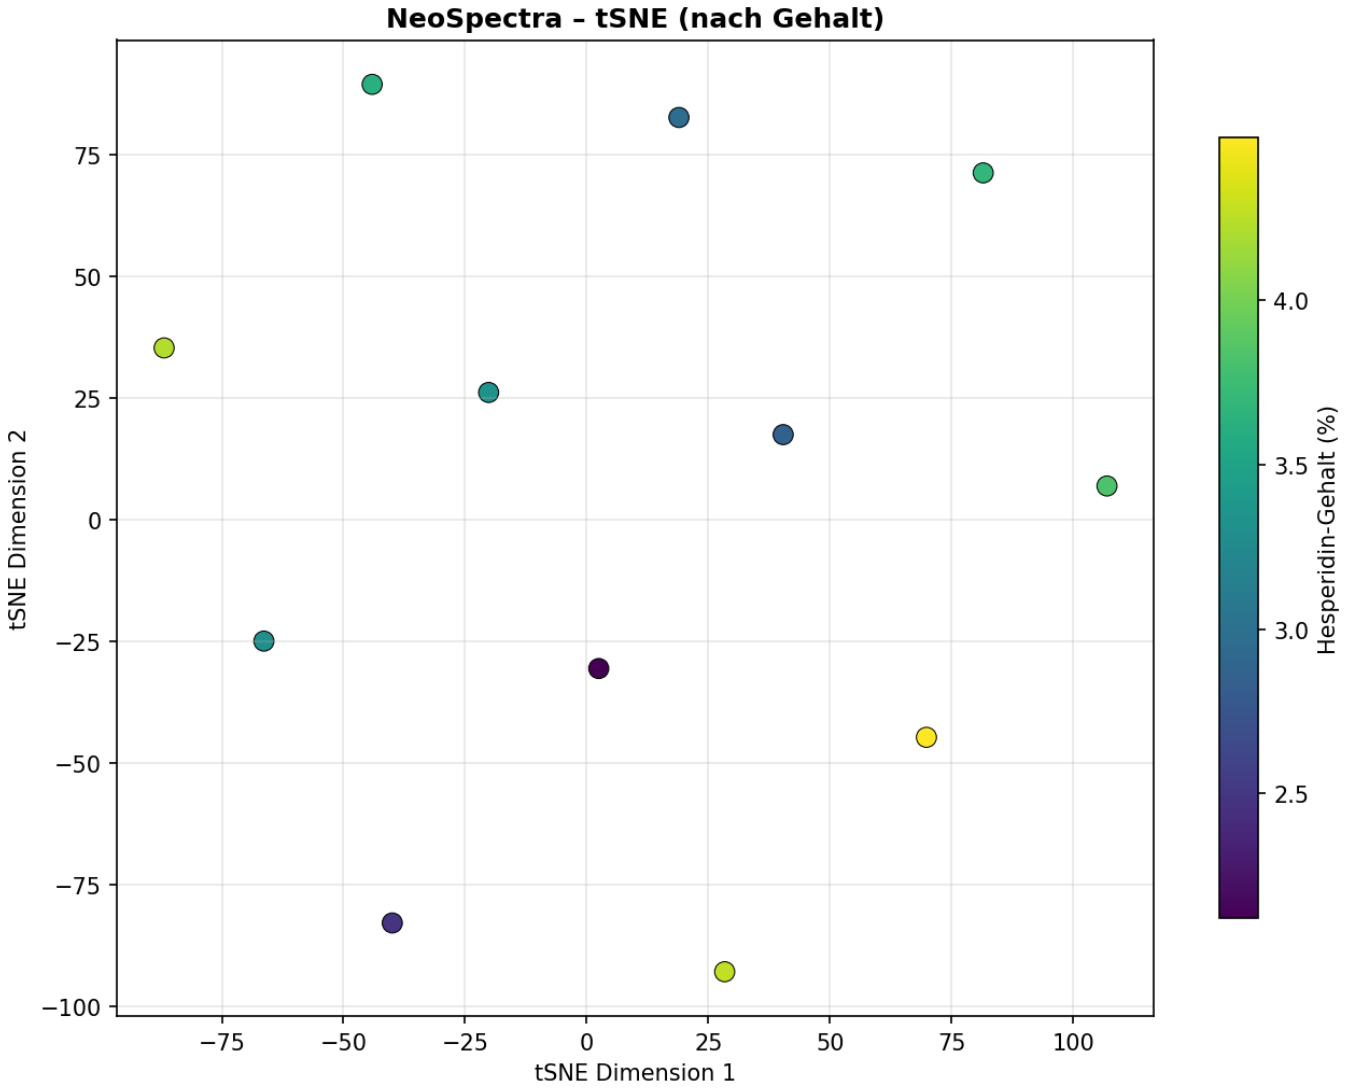

6. Zusammenfassung

Metrik	TANGO	NeoSpectra
Wellenlängenbereich	4000–10000 cm^{-1}	1351–2558 nm
Spektrale Auflösung	1501 Punkte	141 Punkte
Proben mit HPLC	12	12
Wiederholungsmessungen	10/Probe	10/Probe
Optimale PLS-Komponenten	1	7
RMSECV	1.19%	0.75%
R^2CV	-1.86	-0.13
PCA Varianz (PC1+PC2)	79.0%	80.2%

Kernerkenntnisse

1. **Datenqualität:** Beide Spektrometer liefern reproduzierbare Spektren (geringe Streuung innerhalb der Wiederholungsmessungen).
2. **PLS-Modelle:** Nicht prädiktiv aufgrund der geringen Probenzahl (n=12). Das NeoSpectra performt tendenziell besser.
3. **Dimensionsreduktion:** PCA zeigt eine gute Varianzaufklärung (≈80% in 2 Komponenten). Die Proben zeigen keine klare Separierung nach Hesperidin-Gehalt, was die schwache PLS-Performance erklärt.
4. **Empfehlung:** Erhöhung der Probenzahl auf mindestens 30–50 für robuste Kalibriermodelle.